

問題 1. (a) 目的関数

$$L(\beta_0, \beta) := \sum_{i=1}^N \log\{1 + \exp(-y_i(\beta_0 + x_i^T \beta))\}$$

を $\beta_j (j = 0, \dots, p)$ で偏微分するとき, $x_{i,0} = 1 (i = 1, \dots, N), v_i := \exp(-y_i(\beta_0 + x_i^T \beta))$ と置くことで

$$\begin{aligned} \frac{\partial L}{\partial \beta_j} &= \sum_{i=1}^N \frac{-y_i \cdot x_{i,j} \exp(-y_i(\beta_0 + x_i^T \beta))}{1 + \exp(-y_i(\beta_0 + x_i^T \beta))} \\ &= - \sum_{i=1}^N \frac{y_i x_{i,j} v_i}{1 + v_i} \end{aligned}$$

とかけることより

$$\nabla L = - \begin{pmatrix} 1 & \cdots & 1 \\ x_{1,1} & \cdots & x_{N,1} \\ \vdots & \ddots & \vdots \\ x_{1,p} & \cdots & x_{N,p} \end{pmatrix} \begin{pmatrix} \frac{y_1 v_1}{1+v_1} \\ \vdots \\ \frac{y_N v_N}{1+v_N} \end{pmatrix} = -X^T u$$

と書くことができる.

(b) (a) で求めた $\frac{\partial L}{\partial \beta_j}$ をさらに β_k で偏微分すると

$$\begin{aligned} \frac{\partial^2 L}{\partial \beta_j \partial \beta_k} &= - \sum_{i=1}^N \left\{ \frac{\partial v_i}{\partial \beta_k} \frac{\partial}{\partial v_i} \left(\frac{y_i x_{i,j} v_i}{1 + v_i} \right) \right\} \\ &= \sum_{i=1}^N y_i^2 x_{i,j} x_{i,k} \frac{v_i}{(1 + v_i)^2} \\ &= \sum_{i=1}^N x_{i,j} x_{i,k} \frac{v_i}{(1 + v_i)^2} \quad (\because y_i \in \{\pm 1\}) \end{aligned}$$

となることより,

$$\begin{aligned} \nabla^2 L &= X^T \begin{pmatrix} \frac{v_1}{(1+v_1)^2} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \frac{v_N}{(1+v_N)^2} \end{pmatrix} X \\ &= X^T W X \end{aligned}$$

と書くことができる.

さらに，上記で求めた行列を用いて作成した，Newton 法により値を更新していくプログラムの実行結果は下の通り．最上段が初期値 ($p+1$ 次元) を，最下段が推定された係数と実際の係数の l_2 ノルムを表す

```

1  #p=2
2  [ 0.63094861 -0.92697651 -0.91072333]
3  [ 0.86047835 -1.14017869 -1.35275858]
4  [ 0.95114002 -1.22561286 -1.50788179]
5  [ 0.96108609 -1.235 -1.52382468]
6  0.7609464718257709
7
8  #p=3
9  [-0.39248015 -0.60068543 -0.6049099 -1.33818295]
10 [-0.46124804 -0.72404346 -0.72430081 -1.87481017]
11 [-0.48976562 -0.77927907 -0.771821 -2.06096778]
12 [-0.49271985 -0.78517205 -0.77653638 -2.0784206 ]
13 0.7252842383848371
14
15 #p=4
16 [ 0.08141478 -0.68484112 0.70987333 -1.50021169 0.0729047 ]
17 [ 0.0575044 -0.92584186 1.0212524 -2.04351767 0.1381232 ]
18 [ 0.05396007 -1.0284011 1.15461278 -2.28043797 0.16276137]
19 [ 0.05397496 -1.04263046 1.17324641 -2.31351461 0.16560318]
20 [ 0.05398124 -1.04286421 1.17355273 -2.31405542 0.16564041]
21 1.183505858275822
22
23 #p=5
24 [-0.44735853 0.1753804 0.74519156 -0.75696786 0.95888674 0.52116991]
25 [-0.51760096 -0.84462375 0.78877956 -1.1092826 0.70638379 -0.42738666]
26 [-0.74273836 -0.84191146 1.08434294 -1.39660604 1.10210054 -0.30626662]
27 [-0.81581402 -0.91371154 1.18648688 -1.52188011 1.2140128 -0.32811659]
28 [-0.82315975 -0.9212835 1.19631503 -1.53466277 1.22504241 -0.33062673]
29 0.8536261412241056
30
31 #p=6
32 [-0.30254961 -0.65441239 -0.7671653 0.89556886 0.82291769 -1.8986078
33 1.09200474]
34 [-0.93939836 -0.85281913 0.71360078 0.24822987 0.12968842 0.23661314
35 0.79192553]
36 [-0.78674208 -0.88892596 0.19398896 0.61617608 0.47178312 -0.73113428

```

```

37 1.06501684]
38 [-0.98383111 -1.13192227 0.26832396 0.75029806 0.56505247 -0.8264384
39 1.33542463]
40 [-1.03257514 -1.1857139 0.28516761 0.78091463 0.59207949 -0.84812315
41 1.40043966]
42 [-1.03483699 -1.18803046 0.28591791 0.7822523 0.59338503 -0.8490672
43 1.40340034]
44 1.0691750340249508

```

p を大きくしていくごとに、シミュレーションの計算が発散してしまう回数が増えていった。 □

問題 2. (a) $\gamma_0 \in \mathbb{R}, \gamma \in \mathbb{R}^p$ を任意にとって固定し, (2.25) 式の指数部全てから $\gamma_0 + x^T \gamma$ を引いた式を変形していくと

$$\begin{aligned}
& \frac{\exp(\beta_{0,k} + x^T \beta^{(k)} - (\gamma_0 + x^T \gamma))}{\sum_{l=1}^K \exp(\beta_{0,k} + x^T \beta^{(l)} - (\gamma_0 + x^T \gamma))} \\
&= \frac{\exp(-(\gamma_0 + x^T \gamma)) \exp(\beta_{0,k} + x^T \beta^{(k)})}{\exp(-(\gamma_0 + x^T \gamma)) \sum_{l=1}^K \exp(\beta_{0,k} + x^T \beta^{(l)})} \\
&= \frac{\exp(\beta_{0,k} + x^T \beta^{(k)})}{\sum_{l=1}^K \exp(\beta_{0,k} + x^T \beta^{(l)})} = P(Y = k | x) \\
\therefore P(Y = k | x) &= \frac{\exp(\beta_{0,k} + x^T \beta^{(k)} - (\gamma_0 + x^T \gamma))}{\sum_{l=1}^K \exp(\beta_{0,k} + x^T \beta^{(l)} - (\gamma_0 + x^T \gamma))}
\end{aligned}$$

となり, 等号が得られることがわかる。

(b) $\beta_{j,1}, \dots, \beta_{j,K}$ の値が求まったとき ($j = 1, \dots, p$), $\sum_{k=1}^K |\beta_{j,k} - \gamma_j|$ の値を最小にする $\gamma_j \in \mathbb{R}$ を求めればよい。またそのような γ_j は $\beta_{j,1}, \dots, \beta_{j,K}$ の中央値になると文中で述べられているので, $\beta_{j,1}, \dots, \beta_{j,K}$ を求めた後にそれらすべてから中央値を引けばよいことがわかる。

(c) $\sum_{k=1}^K \beta_{0,k}$ となるように設定されていることから, 最初に $\beta_{0,1}, \dots, \beta_{0,K}$ の値を求めた後, それらすべてから $\bar{\beta} := \frac{1}{K} \sum_{k=1}^K \beta_{0,k}$ を引いていることがわかる。 □

問題 3. (a) (2.26) 式は観測値 $(x_1, y_1), \dots, (x_N, y_N)$ から得られる尤度関数で

$$\prod_{i=1}^N \frac{\mu_i^{y_i}}{y_i!} e^{-\mu_i} \quad (\mu_i = e^{\beta_0 + x_i^T \beta})$$

となっている。この尤度関数のマイナス対数をとると

$$\begin{aligned} -\log \left(\prod_{i=1}^N \frac{\mu_i^{y_i}}{y_i!} e^{-\mu_i} \right) &= \sum_{i=1}^N \{ \log(y_i!) - y_i \log(\mu_i) + \mu_i \} \\ &= \sum_{i=1}^N \{ \log(y_i!) - y_i(\beta_0 + x_i^T \beta) + e^{\beta_0 + x_i^T \beta} \} \\ &= L(\beta_0, \beta) + \sum_{i=1}^N \log(y_i!) \end{aligned}$$

となる。最下段の β_0, β に関する最小化は $\frac{1}{N}L(\beta_0, \beta)$ の β_0, β に関する最小化と同値であり、この式に正則化項をつけると

$$\frac{1}{N}L(\beta_0, \beta) + \lambda \|\beta\|_1$$

となる。このようにして (2.27) 式が導出される。

(b) $L(\beta_0, \beta) = \sum_{i=1}^N \{ y_i(\beta_0 + x_i^T \beta) - e^{\beta_0 + x_i^T \beta} \}$ を $\beta_j (j = 0, \dots, p)$ で微分すると

$$\begin{aligned} \frac{\partial L}{\partial \beta_j} &= \sum_{i=1}^N \{ -y_i x_{i,j} + x_{i,j} e^{\beta_0 + x_i^T \beta} \} \\ &= - \sum_{i=1}^N x_{i,j} (y_i - e^{\beta_0 + x_i^T \beta}) \end{aligned}$$

となる。ただし $x_{i,0} = 1 (i = 1, \dots, N)$ とした。よって

$$\nabla L = - \begin{pmatrix} 1 & \cdots & 1 \\ x_{1,1} & \cdots & x_{N,1} \\ \vdots & \ddots & \vdots \\ x_{1,p} & \cdots & x_{N,p} \end{pmatrix} \begin{pmatrix} y_1 - e^{\beta_0 + x_1^T \beta} \\ \vdots \\ y_N - e^{\beta_0 + x_N^T \beta} \end{pmatrix}$$

となるので、

$$u = \begin{pmatrix} y_1 - e^{\beta_0 + x_1^T \beta} \\ \vdots \\ y_N - e^{\beta_0 + x_N^T \beta} \end{pmatrix}$$

とすれば $\nabla L = -X^T u$ とかくことができる。

(c) (b) で得られた $\frac{\partial L}{\partial \beta_j}$ をさらに β_k で偏微分すると

$$\frac{\partial}{\partial \beta_k} \left(\frac{\partial L}{\partial \beta_j} \right) = - \sum_{i=1}^N x_{i,j} x_{i,k} e^{\beta_0 + x_i^T \beta}$$

となることより

$$\nabla^2 L = X^T \begin{pmatrix} e^{\beta_0 + x_1^T \beta} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & e^{\beta_0 + x_N^T \beta} \end{pmatrix} X$$

となるので,

$$W = \begin{pmatrix} e^{\beta_0 + x_1^T \beta} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & e^{\beta_0 + x_N^T \beta} \end{pmatrix}$$

とすれば $\nabla^2 L = X^T W X$ と書くことができる. □

また掲載されているプログラムの空欄を埋めてコード, およびそれを実行した結果は下のようになる

```

1 def poisson_lasso(X, y, lam):
2     p = X.shape[1] # pはすべて1の列を含んでいる
3     beta = np.random.randn(p)
4     gamma = np.random.randn(p)
5     while np.sum((beta - gamma) ** 2) > 0.0001:
6         beta = gamma
7         s = np.dot(X, beta)
8         w = np.exp(s) #空欄1
9         u = y - w #空欄2
10        z = s + u / w ##空欄3
11        gamma_0, gamma_1 = W_linear_lasso(X[:, range(1, p)],
12                                           z, np.diag(w), lam)
13        gamma = np.block([gamma_0, gamma_1]).copy()
14        print(gamma)
15    return gamma
16
17 N = 100
18 p = 3
19 X = np.random.randn(N, p)
20 X = np.concatenate([np.ones(N).reshape(N, 1), X], axis=1)
21 beta = np.random.randn(p + 1)
```

```

22 s = np.dot(X, beta)
23 y = np.random.poisson(lam=np.exp(s))
24 print(beta)

```

```

1 [-0.47085992 -0.31067144 0.30882489 -0.00316935] #真のbの値
2 [ 0.7654697 0. -0. -0. ]
3 [ 0.05384126 -0. 0. 0. ]
4 [-0.35865758 -0. 0. 0. ]
5 [-0.4711855 -0. 0. 0. ]
6 [-0.47801239 -0. 0. 0. ]#推定されたb

```

推定された β がスパースなものであることが確認できた。

□

問題 4. (a) 関数 L は

$$L(\beta) := - \sum_{i:\delta_i=1} \log \frac{e^{x_i^T \beta}}{\sum_{j \in R_i} e^{x_j^T \beta}}$$

で定義されている。この関数 L を β_k で偏微分すると

$$\begin{aligned} \frac{\partial L}{\partial \beta_k} &= - \sum_{i:\delta_i=1} \left\{ x_{i,k} - \frac{\sum_{j \in R_i} x_{j,k} \exp(x_j^T \beta)}{\sum_{h \in R_i} \exp(x_h^T \beta)} \right\} \\ &= - \sum_{i=1}^N x_{i,k} \left\{ \delta_i - \sum_{j \in C_i} \frac{\exp(x_i^T \beta)}{\sum_{h \in R_j} \exp(x_h^T \beta)} \right\} \end{aligned}$$

とかくことができる。ここで、 $S_i \alpha = \sum_{h \in R_i} \exp(x_h^T \beta)$ としたときに

$$\begin{aligned} \sum_{i:\delta_i=1} \sum_{j \in R_j} \frac{x_{j,k} \exp(x_j^T \beta)}{S_i} &= \sum_{i=1}^N \sum_{i \in C_i} \frac{x_{j,k} \exp(x_j^T \beta)}{S_i} \\ &= \sum_{i=1}^N x_{i,k} \sum_{j \in C_i} \frac{\exp(x_i^T \beta)}{S_j} \end{aligned}$$

と変形できることより

$$\frac{\partial L}{\partial \beta_k} = - \sum_{i=1}^N x_{i,k} \left\{ \delta_i - \sum_{j \in C_i} \frac{\exp(x_i^T \beta)}{\sum_{h \in R_j} \exp(x_h^T \beta)} \right\}$$

となることがわかる。したがって

$$\nabla L = -X^T \begin{pmatrix} \delta_1 - \sum_{j \in C_1} \frac{\exp(x_1^T \beta)}{\sum_{h \in R_j} \exp(x_h^T \beta)} \\ \vdots \\ \delta_N - \sum_{j \in C_N} \frac{\exp(x_1^T \beta)}{\sum_{h \in R_j} \exp(x_h^T \beta)} \end{pmatrix}$$

となることより、求める u は

$$u = \begin{pmatrix} \delta_1 - \sum_{j \in C_1} \frac{\exp(x_1^T \beta)}{\sum_{h \in R_j} \exp(x_h^T \beta)} \\ \vdots \\ \delta_N - \sum_{j \in C_N} \frac{\exp(x_1^T \beta)}{\sum_{h \in R_j} \exp(x_h^T \beta)} \end{pmatrix}$$

とかける。

(b) $\nabla^2 L$ の各成分を変形していくと以下のようなになる

$$\begin{aligned} \frac{\partial L}{\partial \beta_k \partial \beta_l} &= \sum_{i=1}^N \sum_{j \in C_i} \frac{\partial}{\partial \beta_l} \left(\frac{\exp(x_i^T \beta)}{\sum_{h \in R_j} \exp(x_h^T \beta)} \right) \\ &= \sum_{i=1}^N x_{i,k} \sum_{j \in C_i} \frac{1}{(\sum_{r \in R_j} \exp(x_r^T \beta))^2} \left\{ x_{i,l} \exp(x_i^T \beta) \sum_{s \in R_j} \exp(x_s^T \beta) \right. \\ &\quad \left. - \exp(x_i^T \beta) \sum_{h \in R_j} x_{h,l} \exp(x_h^T \beta) \right\} \\ &= \sum_{i=1}^N \sum_{h=1}^N x_{i,k} x_{h,l} \sum_{j \in C_i} \frac{\exp(x_i^T \beta)}{(\sum_{t \in R_j} \exp(x_t^T \beta))^2} \left\{ I(i=h) \sum_{s \in R_j} \exp(x_s^T \beta) - I(h \in R_j) \exp(x_h^T \beta) \right\} \end{aligned}$$

とかける。ここで W の対角成分、すなわち $i=h$ となる成分は

$$w_i = \sum_{j \in C_i} \frac{\exp(x_i^T \beta)}{(\sum_{t \in R_j} \exp(x_t^T \beta))^2} \left\{ \sum_{s \in R_j} \exp(x_s^T \beta) - I(h \in R_j) \exp(x_i^T \beta) \right\}$$

とかくことができ、

$$\delta_i = 1, j \in R_i \Leftrightarrow i \in C_i$$

であることより $i=h$ ならば $j \in C_i \Leftrightarrow i=h \in R_j$ が得られる。したがって

$$\pi_{i,j} := \frac{\exp(x_i^T \beta)}{\sum_{r \in R_j} \exp(x_r^T \beta)}$$

とすることで、 W の各対角成分 w_i は

$$w_i = \sum_{j \in C_i} \frac{\exp(x_i^T \beta)}{\sum_{r \in R_j} \exp(x_i^T \beta)} \left\{ 1 - \frac{\exp(x_i - T\beta)}{\sum_{r \in R_j} \exp(x_i^T \beta)} \right\} = \sum_{j \in C_i} \pi_{i,j} (1 - \pi_{i,j})$$

とかける。

□