

近接勾配法

(3.5) 式

$$\frac{1}{2}\|y - X\beta\|_2^2 + \lambda\|\beta\|_2 \quad (3.5)$$

の最小化問題に対するアプローチとして, (3.10) 式, (3.11) 式

$$\gamma := \beta + \nu X^T(y - X\beta) \quad (3.10)$$

$$\beta = \left(1 - \frac{\nu\lambda}{\|\gamma\|_2}\right)_+ \gamma \quad (3.11)$$

を繰り返すことを前節で考えたが, 一般には上式が (3.5) 式の最適解に収束することは保証されない。以下では $\nu > 0$ の値を上手く設定することによって (3.10), (3.11) 式のループによって正しい解に収束することを示す。

まず $\lambda = 0$ の場合であれば (3.11) 式において

$$\beta = \gamma$$

となるため, (3.10) 式と (3.11) 式のループは

$$\beta_{t+1} \leftarrow \beta_t + \nu X^T(y - X\beta_t)\gamma$$

とかけらことに注意したい。ここで, $g(\beta) = \|y - X\beta\|_2^2$ と定めれば $\nabla g(\beta) = -X^T(y - X\beta)$ とかけることより, 上式は

$$\beta_{t+1} \leftarrow \beta_t - \nu \nabla g(\beta_t)$$

と書くことにする。この方法は g の減少の大きい方向に β を更新していくという意味で, 勾配法と呼ばれている。

以下では, (3.5) 式の第 2 項を $h(\beta) := \lambda\|\beta\|_2$ とおいて, $\lambda > 0$ での勾配法を

$$\beta_{t+1} \leftarrow \beta_t - \nu\{\nabla g(\beta_t) + \partial h(\beta)\} \quad (1)$$

とした場合の収束性について考えたい。ここで, 関数 h に対して写像 $\text{prox}_h : \mathbb{R}^p \rightarrow \mathcal{P}(\mathbb{R}^p)$ を

$$\text{prox}_h(z) := \operatorname{argmin}_{\theta \in \mathbb{R}^p} \left\{ \frac{1}{2}\|z - \theta\|_2^2 + h(\theta) \right\}$$

とすることで, (1) 式は

$$\beta_{t+1} \leftarrow \text{prox}_{\nu h}(\beta_t - \nu \nabla g(\beta_t))$$

とかけること，すなわち (1) 式で更新される β は

$$\varphi(\theta) = \frac{1}{2}\|\beta_t - \nu\nabla g(\beta_t) - \theta\|_2^2 + \nu h(\beta)$$

を最小にする θ と一致することを以下で確認する．

最初に $\varphi(\theta)$ を最小にする θ' について考える；まず $\beta_t - \nu\nabla g(\beta_t) = 0$ であるとき， $\varphi(\theta) = \frac{1}{2}\|\theta\|_2^2 + \nu h(\theta) \geq 0$ であり，等号成立は $\theta = 0$ のときに限ることより，求める θ' は $\theta' = 0$ であることがわかる．

次に $\beta_t - \nu\nabla g(\beta_t) \neq 0$ であるとき， $\theta \neq 0$ における $\frac{\partial \varphi(\theta)}{\partial \theta}$ を求めると

$$\frac{\partial \varphi(\theta)}{\partial \theta} = -(\beta_t - \nu\nabla g(\beta_t) - \theta) + \frac{\nu\lambda\theta}{\|\theta\|_2}$$

となるので， $\varphi(\theta)$ を最小にする θ' は

$$\beta_t - \nu\nabla g(\beta_t) - \theta' = \frac{\nu\lambda\theta'}{\|\theta'\|_2} \quad (2)$$

を満たしている．ここで $\tilde{\beta}_t := \beta_t - \nu\nabla g(\beta_t)$ とおくと，上式はある実数 $\alpha \neq 0$ が存在して θ' が

$$\theta' = \alpha\tilde{\beta}_t$$

とかけことを意味している．したがってこれを (2) 式に代入することで

$$\begin{aligned} \tilde{\beta}_t - \alpha\tilde{\beta}_t &= \frac{\nu\lambda\alpha}{|\alpha|\|\tilde{\beta}_t\|_2}\tilde{\beta}_t \\ \alpha\tilde{\beta}_t &= \left(1 - \frac{\nu\lambda\alpha}{|\alpha|\|\tilde{\beta}_t\|_2}\right)\tilde{\beta}_t \end{aligned}$$

が成立することがわかり， $\tilde{\beta}_t \neq 0$ であることから上式の係数を比較して

$$\begin{aligned} \alpha &= 1 - \frac{\nu\lambda\alpha}{|\alpha|\|\tilde{\beta}_t\|_2} \\ &= 1 - \frac{\nu\lambda}{\|\tilde{\beta}_t\|} \cdot \text{sign}(\alpha) \end{aligned}$$

となることがわかる．ここで，仮に $\alpha < 0$ であるとする

$$0 > \alpha = 1 + \frac{\nu\lambda}{\|\tilde{\beta}_t\|} > 0$$

となってしまう，矛盾が生じる．したがって $\alpha > 0$ であることがわかるので

$$\alpha = 1 - \frac{\nu\lambda}{\|\tilde{\beta}_t\|}$$

となることがわかる．これを $\theta' = \alpha \tilde{\beta}_t$ に代入することで求める θ' は

$$\begin{aligned}
\theta' &= \left(1 - \frac{\nu\lambda}{\|\tilde{\beta}_t\|}\right) \tilde{\beta}_t \\
&= \tilde{\beta}_t - \frac{\nu\lambda}{\|\tilde{\beta}_t\|} \tilde{\beta}_t \\
&= \beta_t - \nu \nabla g(\beta_t) - \frac{\nu\lambda \tilde{\beta}_t}{\|\tilde{\beta}_t\|} \\
&= \beta_t - \nu \nabla g(\beta_t) - \nu \frac{\partial h}{\partial \theta}(\tilde{\beta}_t) \\
\therefore \theta' &= \beta_t - \nu \nabla g(\beta_t) - \nu \frac{\partial h}{\partial \theta}(\tilde{\beta}_t)
\end{aligned}$$

となることがわかる．

以上より $\varphi(\theta)$ を最小にする θ' は

$$\theta' = \begin{cases} \beta_t - \nu \left\{ \nabla(\beta_t) - \frac{\partial h}{\partial \theta}(\tilde{\beta}_t) \right\} & (\beta_t - \nu \nabla(\beta_t) \neq 0 \text{ のとき}) \\ 0 & (\beta_t - \nu \nabla(\beta_t) = 0 \text{ のとき}) \end{cases}$$

と書くことができるが，関数 h の劣微分が 0 を含むことから改めて

$$\theta' \in \beta_t - \nu \left\{ \nabla(\beta_t) - \partial h(\tilde{\beta}_t) \right\}$$

とかくことができ，これは (1) 式と一致することがわかる．

上記より，新たに提案された勾配法は

$$\beta_{t+1} \leftarrow \text{prox}_{\nu h}(\beta_t - \nu \nabla g(\beta_t))$$

とかけることが確認できた．ここで $\text{prox}_{\nu h}(\beta_t - \nu \nabla g(\beta_t))$ が実際には

$$\text{prox}_{\nu h}(\beta_t - \nu \nabla g(\beta_t)) = \left(1 - \frac{\nu\lambda}{\|\tilde{\beta}_t\|}\right)_+ \tilde{\beta}_t$$

とかけていたことから更新式は

$$\begin{aligned}
\gamma &\leftarrow \beta - \nu \nabla g(\beta_t) = \beta + \nu X^T(y - X\beta) \\
\beta &\leftarrow \left(1 - \frac{\nu\lambda}{\|\gamma\|_2}\right)_+ \gamma
\end{aligned}$$

とかけることがわかる．これは (3.10),(3.11) の更新式に他ならない．

最後に ν を上手くとることができれば, 上記の更新式によって $f(\beta)$ を最小にする β_* を求められることを示す.

まず $X^T X$ の最大固有値を L とすれば, 任意の $x, y, z \in \mathbb{R}^p$ に対して

$$(x - y)^T \nabla^2 g(z)(x - y) \leq L \|x - y\|_2^2$$

が成立することを示す; $X^T X$ が対称行列であることから, ある直交行列 P が存在して

$$P^T (X^T X) P = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_p \end{pmatrix}$$

が成立する. さらに L の定め方より, 任意の $x = (x_1, \dots, x_p)^T \in \mathbb{R}^p$ に対して I を p 次単位行列として

$$\begin{aligned} x^T P^T L I P x &= L \cdot x^T P^T P x \\ &= L \sum_{i=1}^p x_i^2 \geq \sum_{i=1}^p \lambda_i x_i^2 \\ &= x^T \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_p \end{pmatrix} x \\ &= x^T P^T (X^T X) P x \end{aligned}$$

が任意の $x \in \mathbb{R}^p$ に対して成立していることより, $x \rightarrow P^T(x - y)$ とおけば

$$\begin{aligned} (x - y)^T \nabla^2 g(z)(x - y) &= \{P^T(x - y)\}^T P^T (X^T X) P \{P^T(x - y)\} \\ &\leq \{P^T(x - y)\}^T P^T L I P \{P^T(x - y)\}^T \\ &= L \|x - y\|_2^2 \\ \therefore (x - y)^T \nabla^2 g(z)(x - y) &\leq L \|x - y\|_2^2 \end{aligned}$$

となり, 求めたい不等式が導ける.

また, (3.13) 式について

$$\begin{aligned} \text{prox}_{\nu h}(\beta_t - \nu \nabla g(\beta_t)) &= \operatorname{argmin}_{\theta \in \mathbb{R}^p} \left\{ \frac{1}{2} \|\beta_t - \nu \nabla g(\beta_t) - \theta\|_2^2 + \nu h(\theta) \right\} \\ &= \operatorname{argmin}_{\theta \in \mathbb{R}^p} \left\{ \frac{1}{2\nu} \|\beta_t - \nu \nabla g(\beta_t) - \theta\|_2^2 + h(\theta) + g(\beta_t) \right\} \\ &= \operatorname{argmin}_{\theta \in \mathbb{R}^p} \left\{ \frac{1}{2\nu} \|\beta_t - \theta\|_2^2 + (\beta_t - \theta)^T \nabla g(\beta_t) + h(\theta) + g(\beta_t) \right\} \end{aligned}$$

が成立することより, $\nu = \frac{1}{L}$ とした (3.13) 式を

$$Q(x, y) := g(y) + (x - y)^T \nabla g(y) + \frac{L}{2} \|x - y\|_2^2 + h(x)$$

$$p(y) := \operatorname{argmin}_{x \in \mathbb{R}^p} Q(x, y)$$

を用いて

$$\beta_{t+1} \leftarrow p(\beta_t) \quad (3)$$

と書きなおしておく.*1

以上で定めた定数 L , 写像 Q, p に対し, 次の命題 7 が成立する

命題 7

(3) 式によって生成された列 $\{\beta_t\}$ は, f の最小化問題に対する最適解を β_* としして次式を満たす

$$f(\beta_k) - f(\beta_*) \leq \frac{L \|\beta_0 - \beta_*\|_2^2}{2k}$$

証明には以下の補題 1 を用いる.

補題 1

任意の $x, y \in \mathbb{R}^p$ に対して

$$\frac{2}{L} f(x) - f(p(y)) \geq \|p(y) - y\|_2^2 + 2(y - x)^T (p(y) - y)$$

が成立する.

Proof. 自然数 k を任意にとりて固定する. 補題 1 で $x = \beta_*, y = \beta_t$ とおき, さらに $p(\beta) = \beta_{t+1}$ であることを用いれば

$$\begin{aligned} \frac{2}{L} \{f(\beta_*) - f(\beta_{t+1})\} &\geq \|\beta_{t+1} - \beta_t\|_2^2 + 2(\beta_t - \beta_*)^T (\beta_{t+1} - \beta_t) \\ &= \langle \beta_{t+1} - \beta_t, \beta_{t+1} - \beta_t + 2(\beta_t - \beta_*) \rangle \\ &= \langle (\beta_{t+1} - \beta_*) - (\beta_t - \beta_*), (\beta_{t+1} - \beta_*) + (\beta_t - \beta_*) \rangle \\ &= \|\beta_{t+1} - \beta_*\|_2^2 - \|\beta_t - \beta_*\|_2^2 \end{aligned}$$

が任意の自然数 $t \leq k$ に対して成立することがわかる. したがって上の不等式を $t = 0, \dots, k-1$ について足し合わせれば

$$\frac{2}{L} \left\{ k f(\beta_*) - \sum_{t=0}^{k-1} f(\beta_{t+1}) \right\} \geq \|\beta_* - \beta_k\|_2^2 - \|\beta_* - \beta_0\|_2^2 \quad (4)$$

*1 この方法は ISTA (Iterative Shrinkage-Thresholding Algorithm) と呼ばれる

が成立することがわかる。さらに $x = y = \beta_t$ として再び補題 1 を適用すると

$$\frac{2}{L} \{f(\beta_t) - f(\beta_{t+1})\} \geq \|\beta_{t+1} - \beta_t\|_2^2$$

となることより、上式の両辺を t 倍し、さらに $t = 0, \dots, k-1$ について加えることで

$$\frac{2}{L} \sum_{t=0}^{k-1} t \{f(\beta_t) - f(\beta_{t+1})\} = \frac{2}{L} \sum_{t=0}^{k-1} \{tf(\beta_t) - (t+1)f(\beta_{t+1}) + f(\beta_{t+1})\} \quad (5)$$

$$= \frac{2}{L} \left\{ -kf(\beta_k) + \sum_{t=0}^{k-1} f(\beta_{t+1}) \right\} \geq \sum_{t=0}^{k-1} t \|\beta_t - \beta_{t+1}\|_2^2 \quad (6)$$

が成立することがわかる。以上で得られた不等式 (4), (6) の両辺を加えることで

$$\begin{aligned} \frac{2k}{L} \{f(\beta_*) - f(\beta_k)\} &\geq \|\beta_* - \beta_k\|_2^2 - \|\beta_* - \beta_0\|_2^2 + \sum_{t=0}^{k-1} t \|\beta_t - \beta_{t+1}\|_2^2 \\ &\geq -\|\beta_* - \beta_0\|_2^2 \\ \therefore f(\beta_k) - f(\beta_*) &\leq \frac{L\|\beta_0 - \beta_*\|_2^2}{2k} \end{aligned}$$

が得られる。これが求めたかった不等式である。 □

ISTA の修正アルゴリズムとして、次を考える；実数列 $\{\alpha_t\}$ を

$$\alpha_1 = 1, \quad \alpha_{t+1} := \frac{1 + \sqrt{1 + 4\alpha_t^2}}{2}$$

によって定め、さらに初期値 β_0 に対して $\gamma_1 = \beta_0$ として更新式を

$$\begin{aligned} \beta_t &\leftarrow p(\gamma_t) \\ \gamma_{t+1} &\leftarrow \beta_t + \frac{\alpha_t - 1}{\alpha_{t+1}} (\beta_t - \beta_{t-1}) \end{aligned}$$

によって定める。この手法は FISTA^{*2} と呼ばれ、得られる列 $\{\beta_t\}$ は次の命題 8 を満たす

命題 8

FISTA によって生成された数列 $\{\beta_t\}$ は、 f の最小化問題に対する最適解を β_* として次式を満たす

$$f(\beta_k) - f(\beta_*) \leq \frac{4L\|\beta_0 - \beta_*\|_2^2}{(k+1)^2}$$

証明には以下の補題 2, 3, 4 を用いる

^{*2} Fast Iterative Shrinkage-Thresholding Algorithm

補題 2

FISTA で考える列 $\{\alpha_k\}$ と得られる列 $\{\beta_k\}$, 及び最適解 β_* に対して次式が成立する

$$\frac{2}{L} \{ \alpha_k^2 (f(\beta_k) - f(\beta_*)) - \alpha_{k+1}^2 (f(\beta_{k+1}) - f(\beta_*)) \} \geq t_{k+1} - t_k$$

ただし $t_k := \|\alpha_k \beta_k - (\alpha_k - 1) \beta_{k-1} - \beta_*\|_2^2$ とする.

補題 3

ある実数 c が存在して, 2 つの非負値実数列 $\{a_k, b_k\}$ が任意の自然数 $k \geq 1$ について

$$a_k - a_{k+1} \geq b_{k+1} - b_k \text{ かつ } a_1 + b_1 \leq c$$

を満たすならば, 任意の自然数 k に対して $a_k \leq c$ が成立する.

補題 4

FISTA で考える列 $\{\alpha_k\}$ は任意の自然数 $k \geq 1$ に対して

$$\alpha_k \geq \frac{k+1}{2}$$

が成立する.

Proof. 補題 2 より

$$\frac{2}{L} \alpha_k^2 (f(\beta_k) - f(\beta_*)) - \frac{2}{L} \alpha_{k+1}^2 (f(\beta_{k+1}) - f(\beta_*)) \geq t_{k+1} - t_k$$

が成立する. ここで, $s_k := \frac{2}{L} \alpha_k^2 (f(\beta_k) - f(\beta_*))$ とすることで上式は

$$s_k - s_{k+1} \geq t_{k+1} - t_k \tag{7}$$

と書き直せる. さらに $\{s_k\}, \{t_k\}$ は共に非負値実数列で (7) 式及び

$$s_1 + t_1 \leq 2\|\beta_0 - \beta_*\|_2^2$$

を満たすので, $c = 2\|\beta_0 - \beta_*\|_2^2$ として補題 3 を適用すれば

$$s_k \leq c \Leftrightarrow \frac{2}{L} \alpha_k^2 (f(\beta_k) - f(\beta_*)) \leq 2\|\beta_0 - \beta_*\|_2^2$$

が得られる. 上式に補題 4 を適用すれば, 任意の自然数 k に対して

$$\begin{aligned} f(\beta_k) - f(\beta_*) &\leq L\|\beta_0 - \beta_*\|_2^2 \cdot \frac{1}{\alpha_k^2} \\ &\leq L\|\beta_0 - \beta_*\|_2^2 \cdot \frac{4}{(k+1)^2} = \frac{4L\|\beta_0 - \beta_*\|_2^2}{(k+1)^2} \end{aligned}$$

が成立することがわかる. これが求めたかった不等式である. \square