

3.5 オーバーラップグループ Lasso

説明変数に関して $\{1, 2, 3\}, \{3, 4, 5\}$ のように、グループに含まれる変数が重複する場合にもグループ Lasso の処理を構成したい。グループ $k = 1, \dots, K$ において、変数に対する係数 β_1, \dots, β_p のうち、用いない変数 β_k については 0 とおく。また $\mathbb{R}^p \ni \beta = \sum_{k=1}^K \theta_k$ を満たす $\theta_1, \dots, \theta_k \in \mathbb{R}^p$ を用意する。そして、与えられる $X \in \mathbb{R}^{N \times p}, y \in \mathbb{R}^N$ から

$$L(\theta) = \frac{1}{2} \left\| y - X \sum_{k=1}^K \theta_k \right\|_2^2 + \lambda \sum_{k=1}^K \|\theta_k\|_2$$

を最小にする θ を求めることを考える。

例として、 $p = 5, K = 2$ で β_3 のみがオーバーラップしている場合を考える。この場合、 θ_1, θ_2 は以下ようになる

$$\theta_1 = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_{3,1} \\ 0 \\ 0 \end{bmatrix}, \quad \theta_2 = \begin{bmatrix} 0 \\ 0 \\ \beta_{3,2} \\ \beta_4 \\ \beta_5 \end{bmatrix} \quad (\beta_3 = \beta_{3,1} + \beta_{3,2}).$$

ここで、 $X \in \mathbb{R}^{N \times 5}$ の最初の 3 列を $X_1 \in \mathbb{R}^{N \times 3}$, 最後の 3 列を $X_2 \in \mathbb{R}^{N \times 3}$ と書き、 L について θ_1, θ_2 の最初の 3 成分 γ_1, γ_2 で劣微分をとると

$$\begin{aligned} \frac{\partial L}{\partial \gamma_1} &= \begin{bmatrix} \frac{\partial L}{\partial \beta_1} \\ \frac{\partial L}{\partial \beta_2} \\ \frac{\partial L}{\partial \beta_{3,1}} \end{bmatrix} = -X_1^T (y - X_1 \gamma_1) + \lambda \partial \|\gamma_1\|_2 \\ \frac{\partial L}{\partial \gamma_2} &= \begin{bmatrix} \frac{\partial L}{\partial \beta_{3,2}} \\ \frac{\partial L}{\partial \beta_4} \\ \frac{\partial L}{\partial \beta_5} \end{bmatrix} = -X_2^T (y - X_2 \gamma_2) + \lambda \partial \|\gamma_2\|_2 \end{aligned}$$

となることがわかるので、グループ数が 1 の場合での全体の微分が 0 を含むとした (3.8) 式は

$$\begin{aligned} -X_1^T (y - X \theta_1) + \lambda \partial \|\theta_1\|_2 &= 0 \\ -X_2^T (y - X \theta_2) + \lambda \partial \|\theta_2\|_2 &= 0 \end{aligned}$$

に相当することがわかる。したがって $\theta_j = 0 (j = 1, 2)$ で最小となる時 $\|X_j^T y\|_2 \leq \lambda$ が成立することから、結局オーバーラップがあった場合でも通常のグループ Lasso と同じ手法

で最適化ができることがわかる.

3.6 目的変数が複数個ある場合のグループ Lasso

観測データ $X \in \mathbb{R}^{N \times p}$, $\beta \in \mathbb{R}^{p \times K}$, $y \in \mathbb{R}^{N \times K}$ から

$$L_0(\beta) := \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^K \left(y_{i,k} - \sum_{j=1}^p x_{i,j} \beta_{j,k} \right)^2 \quad (1)$$

として

$$L(\beta) := L_0(\beta) + \lambda \sum_{j=1}^p \|\beta_j\|_2$$

を最小にする $\beta \in \mathbb{R}^{p \times K}$ を求めたい. 上式で $K = 1$ とすれば, これは第 1 章で扱った Lasso に相当する. $y_i = [y_{i,1}, \dots, y_{i,K}]$ というように目的変数を K 個に拡張した場合, 各 j について $\beta_j = [\beta_{j,1}, \dots, \beta_{j,K}]$ の K 個のアクティブ・非アクティブのタイミングが同じであることを仮定している.

$L(\beta)$ の最小化について考える. (1) 式を $\beta_{j,k}$ で偏微分すると

$$\begin{aligned} \frac{\partial L_0}{\partial \beta_{j,k}} &= \sum_{i=1}^N \{ -x_{i,j} (r_{i,k}^{(j)} - x_{i,j} \beta_{j,k}) \} \\ (\text{ただし } r_{i,k}^{(j)} &:= y_{i,k} - \sum_{h \neq j} x_{i,h} \beta_{h,k}) \end{aligned}$$

となることから $L(\beta)$ の β_j による劣微分は

$$\beta_j \sum_{i=1}^N x_{i,j}^2 - \sum_{i=1}^N x_{i,j} r_i^{(j)} + \lambda \partial \|\beta_j\|_2 \quad (2)$$

となることがわかる. もし $\hat{\beta}_j = 0$ が最適解ならば, (2) が 0 となるのは

$$\begin{aligned} \lambda \partial \|\beta_j\|_2 &\ni \sum_{i=1}^N x_{i,j} r_i^{(j)} \\ \therefore \left\| \sum_{i=1}^N x_{i,j} r_i^{(j)} \right\|_2 &\leq \lambda \end{aligned}$$

のときであり, $\hat{\beta}_j \neq 0$ が最適解であるならば, グループ数が 1 の場合のグループ Lasso と同様の論法により

$$\hat{\beta}_j = \frac{1}{\sum_{i=1}^N x_{i,j}^2} \left(1 - \frac{\lambda}{\left\| \sum_{i=1}^N x_{i,j} r_i^{(j)} \right\|_2} \right) \sum_{i=1}^N x_{i,j} r_i^{(j)}$$

となることがわかる．以上より (2) 式を 0 にする $\hat{\beta}_j$ は

$$\hat{\beta}_j = \frac{1}{\sum_{i=1}^N x_{i,j}^2} \left(1 - \frac{\lambda}{\|\sum_{i=1}^N x_{i,j} r_i^{(j)}\|_2} \right)_+ \sum_{i=1}^N x_{i,j} r_i^{(j)}$$

とかけることがわかる．